

3. Optimización de Costos y Selección del Modelo

3.1. Criterio de selección

El procesamiento de IA del sistema consiste en una tarea acotada de clasificación de leads, donde el modelo analiza el presupuesto y el contenido de una consulta para asignar una prioridad Alta o Baja y generar una justificación breve en formato JSON.

Dado que la tarea no requiere razonamiento complejo, búsqueda web ni análisis documental extenso, se priorizó una solución de baja latencia y bajo costo, evitando utilizar modelos de mayor capacidad cuando no aportan un beneficio proporcional.

3.2. Matriz comparativa

Alternativa	Costo input / 1M tokens	Costo output / 1M tokens	Aplicación recomendada	Decisión
Groq – Llama 3.1 8B Instant	USD 0,05	USD 0,08	Clasificación, extracción y respuestas estructuradas simples	Adecuado para este flujo
Groq – Llama 3.3 70B	USD 0,59	USD 0,79	Tareas que requieran mayor capacidad de razonamiento	Sobredimensionado
OpenAI GPT-4o mini	USD 0,15	USD 0,60	Clasificación y procesamiento estructurado de bajo costo	Alternativa viable
OpenAI GPT-4o	USD 2,50	USD 10,00	Tareas multimodales o de mayor complejidad	Sobredimensionado
Batch API	Descuento sobre procesamiento estándar	—	Grandes volúmenes sin necesidad de respuesta inmediata	Alternativa futura

3.3. Estimación de costo

Escenario: 1.000 leads mensuales

Consumo estimado por lead: 300 tokens de entrada + 100 tokens de salida.

Eso implica aproximadamente:

- 300.000 tokens input/mes.
- 100.000 tokens output/mes.

Si usáramos **Llama 3.1 8B Instant en Groq**, el costo estimado sería:

Input: $0,30 \times \text{USD } 0,05 = \text{USD } 0,015$

Output: $0,10 \times \text{USD } 0,08 = \text{USD } 0,008$

Costo IA estimado: USD 0,023 por cada 1.000 leads.

Es decir, prácticamente despreciable para este caso de uso.

3.4. Procesamiento masivo

Para un escenario futuro de procesamiento masivo de leads históricos, donde no se requiera respuesta inmediata, podría utilizarse una API Batch. Groq informa actualmente una reducción del 50% del costo para cargas procesadas asincrónicamente mediante su Batch API. En el flujo actual no se utiliza esta modalidad porque cada lead debe ser procesado en tiempo cercano al real para ingresar posteriormente al circuito de aprobación humana.

3.5. Conclusión

La arquitectura adopta un modelo liviano para una tarea de baja complejidad y reserva modelos de mayor capacidad para escenarios donde el incremento de calidad justifique su mayor costo. El procesamiento individual se mantiene en tiempo cercano al real debido al circuito HITL, mientras que Batch se considera una alternativa de optimización para futuros procesos masivos no urgentes.